Rapport du Projet

Business Intelligence & Data Mining

Module : Informatique Décisionnelle

Filière : ADIA M1

Encadrant : Pr. Y. Ait Lahcen

Réalisées par :
EL KABOUS Wissal
CHOUINNA Lamaye

Année Universitaire 2025/2026

Sommaire

Sommaire 2
Introduction 2
1. Présentation Générale du Projet 2
1.1 Description du projet comptoirDB 2
1.2 Outils et environnement de travail 2
2. Base de Données Opérationnelle 3
3. Processus ETL avec Talend 4
3.1 Créer une connexion avec une base de données 4
3.2 Dim_Produit 4
3.3Dim_Client 6
3.4 Dim_Temps 8
3.5 Table Fait 8
4. Conception de l'Entrepôt de Données 9
4.1 Schéma conceptuel de l'entrepôt 9
4.2 Traduction en schéma R-OLAP 10
4.3 Modèle en étoile 10
5. Analyse et Tableaux de Bord 11
5.1 Répartition du Chiffre d'affaires par le nom de catégorie 11
5.2 Quantité vendue par produit et par prix unitaire : 12
5.3 Somme des Prix unitaire par jour et par mois : 12
6. Data Mining 13
6.1 Clustering avec K-Means 13
6.2 Règles d'Association avec Apriori ..... **Error! Bookmark not defined.**
Conclusion 14

Introduction

Aujourd'hui, les entreprises disposent d'une grande quantité de données. Pour exploiter ces données et faciliter la prise de décision, on utilise la **Business Intelligence (BI)** et le **Data Mining**.

- **Business Intelligence (BI)** : ensemble de méthodes et d'outils qui permettent d'analyser les données pour aider les décideurs.
- **Data Mining** : techniques qui permettent de découvrir des informations utiles cachées dans les données.

Ce projet consiste à concevoir un **entrepôt de données** à partir de la base **comptoirDB**, puis à analyser ces données à l'aide d'outils de reporting et d'algorithmes de Data Mining.

1. Présentation Générale du Projet

1.1 Description du projet comptoirDB

Le projet comptoirDB consiste à construire un entrepôt de données à partir d'une base de données opérationnelle.
Les données concernent principalement les clients, les produits, les commandes et le temps.

L'objectif principal est de permettre une analyse efficace des ventes et du comportement des clients.

1.2 Outils et environnement de travail

Les outils utilisés dans ce projet sont :

- **SQL Server** : création et gestion de la base de données.
- **Talend Open Studio** : réalisation du processus ETL.
- **Power BI / Excel** : analyse et tableaux de bord.
- **Weka** : application des algorithmes de Data Mining.

ETL : Extract (extraire), Transform (transformer), Load (charger).

2. Base de Données Opérationnelle

La première étape du projet a consisté à créer la base de données **comptoirDB** sous SQL Server.

Cette base contient les données opérationnelles utilisées dans les transactions quotidiennes.

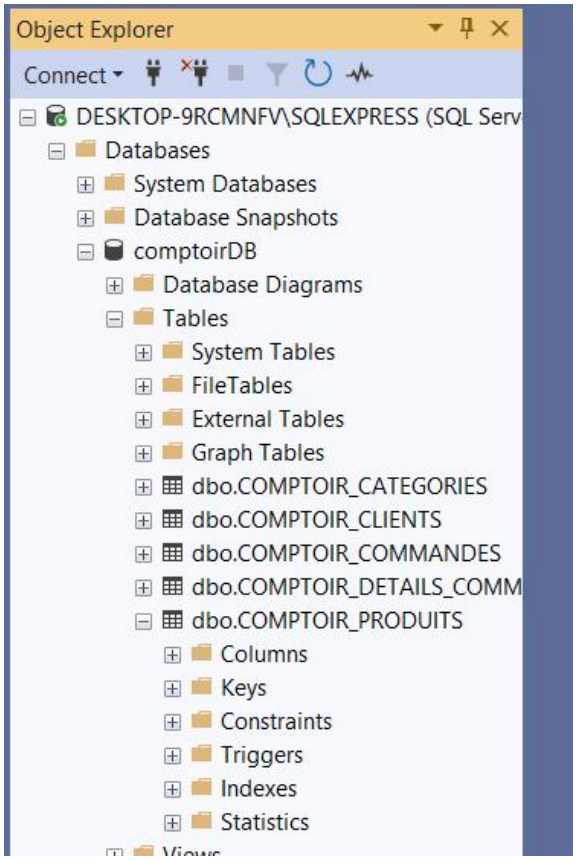

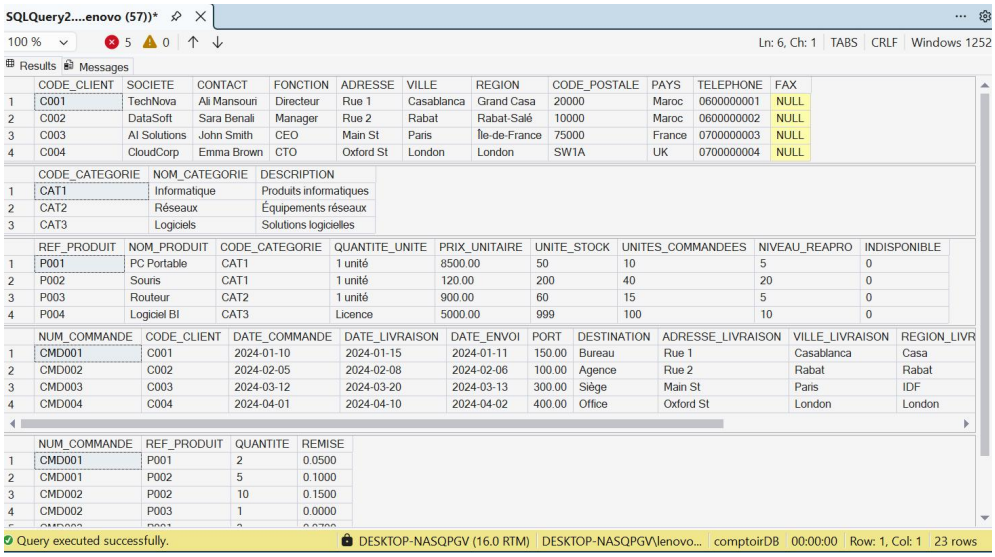

	CODE_CLIENT	SOCIETE	CONTACT	FONCTION	ADRESSE	VILLE	REGION	CODE_POSTALE	PAYS	TELEPHONE	FAX
1	C001	TechNova	Ali Mansouri	Directeur	Rue 1	Casablanca	Grand Casa	20000	Maroc	0600000001	NULL
2	C002	DataSoft	Sara Benali	Manager	Rue 2	Rabat	Rabat-Salé	10000	Maroc	0600000002	NULL
3	C003	AI Solutions	John Smith	CEO	Main St	Paris	Île-de-France	75000	France	0700000003	NULL
4	C004	CloudCorp	Emma Brown	CTO	Oxford St	London	London	SW1A	UK	0700000004	NULL

	CODE_CATEGORIE	NOM_CATEGORIE	DESCRIPTION
1	CAT1	Informatique	Produits informatiques
2	CAT2	Réseaux	Équipements réseaux
3	CAT3	Logiciels	Solutions logicielles

	REF_PRODUIT	NOM_PRODUIT	CODE_CATEGORIE	QUANTITE_UNITE	PRIX_UNITAIRE	UNITE_STOCK	UNITES_COMMANDEES	NIVEAU_REAPRO	INDISPONIBLE
1	P001	PC Portable	CAT1	1 unité	8500.00	50	10	5	0
2	P002	Souris	CAT1	1 unité	120.00	200	40	20	0
3	P003	Routeur	CAT2	1 unité	900.00	60	15	5	0
4	P004	Logiciel BI	CAT3	Licence	5000.00	999	100	10	0

	NUM_COMMANDE	CODE_CLIENT	DATE_COMMANDE	DATE_LIVRAISON	DATE_ENVOI	PORT	DESTINATION	ADRESSE_LIVRAISON	VILLE_LIVRAISON	REGION_LIVR
1	CMD001	C001	2024-01-10	2024-01-15	2024-01-11	150.00	Bureau	Rue 1	Casablanca	Casa
2	CMD002	C002	2024-02-05	2024-02-08	2024-02-06	100.00	Agence	Rue 2	Rabat	Rabat
3	CMD003	C003	2024-03-12	2024-03-20	2024-03-13	300.00	Siège	Main St	Paris	IDF
4	CMD004	C004	2024-04-01	2024-04-10	2024-04-02	400.00	Office	Oxford St	London	London

	NUM_COMMANDE	REF_PRODUIT	QUANTITE	REMISE
1	CMD001	P001	2	0.0500
2	CMD001	P002	5	0.1000
3	CMD002	P002	10	0.1500
4	CMD002	P003	1	0.0000

3. Processus ETL avec Talend

Le processus ETL a été réalisé en trois étapes :

1. **Extraction** des données depuis la base comptoirDB.
2. **Transformation** des données (nettoyage, calculs, formatage).
3. **Chargement** des données dans l'entrepôt.

3.1 Créer une connexion avec une base de données

Dans cette partie, on explique :

- La connexion entre Talend et SQL Server
- Les paramètres utilisés (serveur, base, utilisateur)

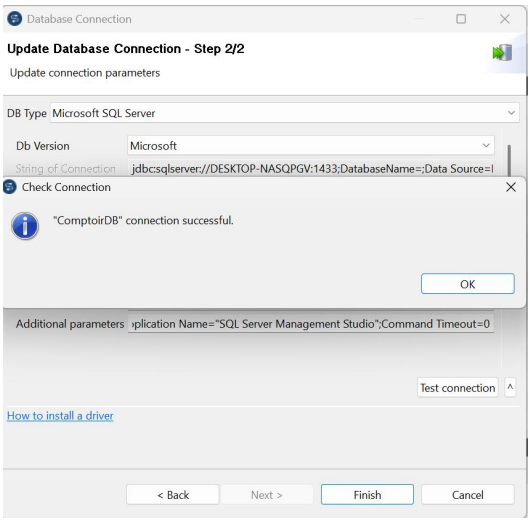

3.2 Dim_Produit

Cette étape concerne la création de la dimension Produit (Dim_Produit) à l'aide de Talend Open Studio. Les données sources proviennent principalement de la table Produits, enrichies par la table Catégories, afin d'obtenir des informations complètes sur chaque produit.

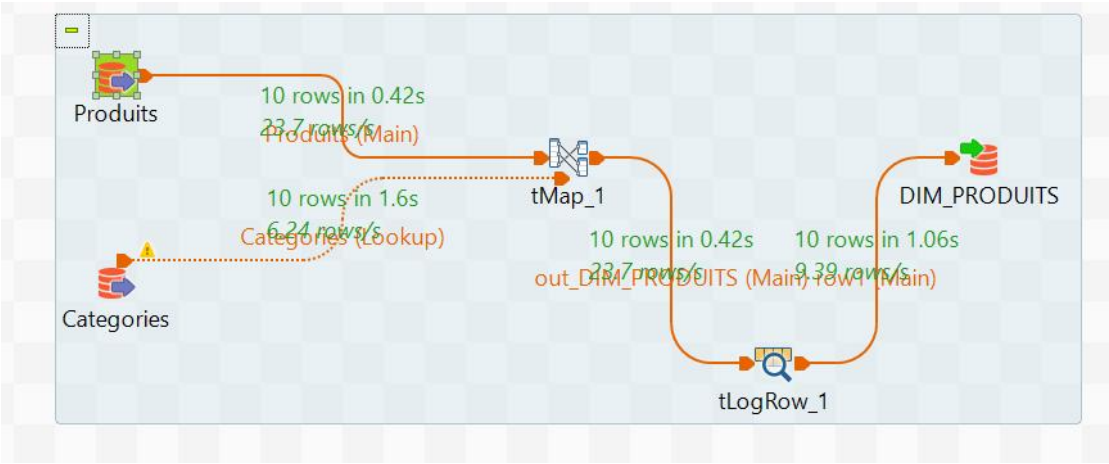

Dans Talend, la table Produits est utilisée comme flux principal (Main), tandis que la table Catégories est utilisée comme flux de recherche (Lookup). Ces deux sources sont reliées à l'aide du composant tMap, qui permet de combiner les données selon le code de catégorie.

- **Lookup** : table utilisée pour ajouter des informations supplémentaires à partir d'une autre table.

- **tMap** : composant Talend permettant de faire des jointures et des transformations.

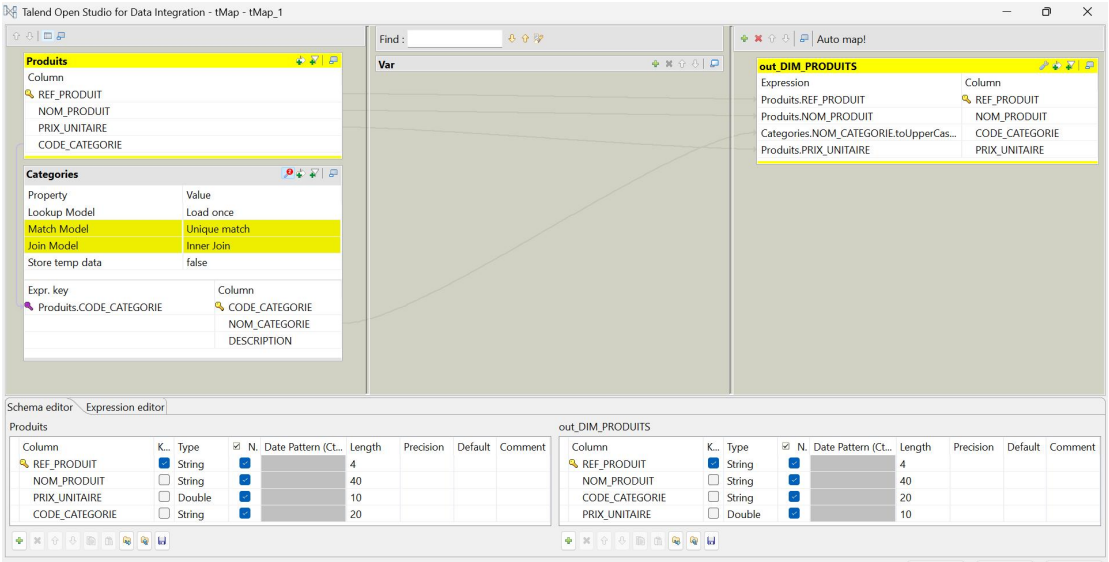

Les transformations réalisées consistent à :

- Associer chaque produit à sa catégorie.
- Sélectionner les attributs nécessaires à la dimension produit.
- Renommer certains champs pour les adapter au modèle décisionnel.

Les attributs retenus pour la dimension **Dim_Produit** sont :

- Référence du produit

- Nom du produit
- Catégorie du produit
- Prix unitaire

SQLQuery3.s...W (sa (65))*

```
USE comptoirDW
GO

Select * from DIM_PRODUITSS;
```

100 % 1 0

Results Messages

	REF_PRODUIT	NOM_PRODUIT	CODE_CATEGORIE	PRIX_UNITAIRE
1	P001	Laptop Lenovo i5	INFORMATIQUE	6500.00
2	P002	PC HP Pavilion	INFORMATIQUE	7200.00
3	P003	Smartphone Samsung A34	TÉLÉPHONIE	3000.00
4	P004	iPhone 13	TÉLÉPHONIE	9500.00
5	P005	Imprimante HP LaserJet	BUREAUTIQUE	2200.00
6	P006	Casque Bluetooth Sony	AUDIO	850.00
7	P007	Enceinte JBL	AUDIO	1200.00
8	P008	Clavier Logitech	ACCESSOIRES	350.00
9	P009	Souris Logitech	ACCESSOIRES	200.00
10	P010	Moniteur Dell 24"	ÉCRANS	2500.00

Après transformation, les données sont chargées dans la table DIM_PRODUITS. Une vérification a ensuite été effectuée à l'aide d'une requête SQL sous SQL Server, confirmant le bon chargement et la cohérence des données.

3.3Dim_Client

Cette étape concerne la création de la dimension Client (**Dim_Client**) à l'aide de **Talend Open** Studio. Les données sont extraites depuis la table Clients de la base SQL Server. Les informations principales des clients sont sélectionnées et préparées pour l'analyse décisionnelle.

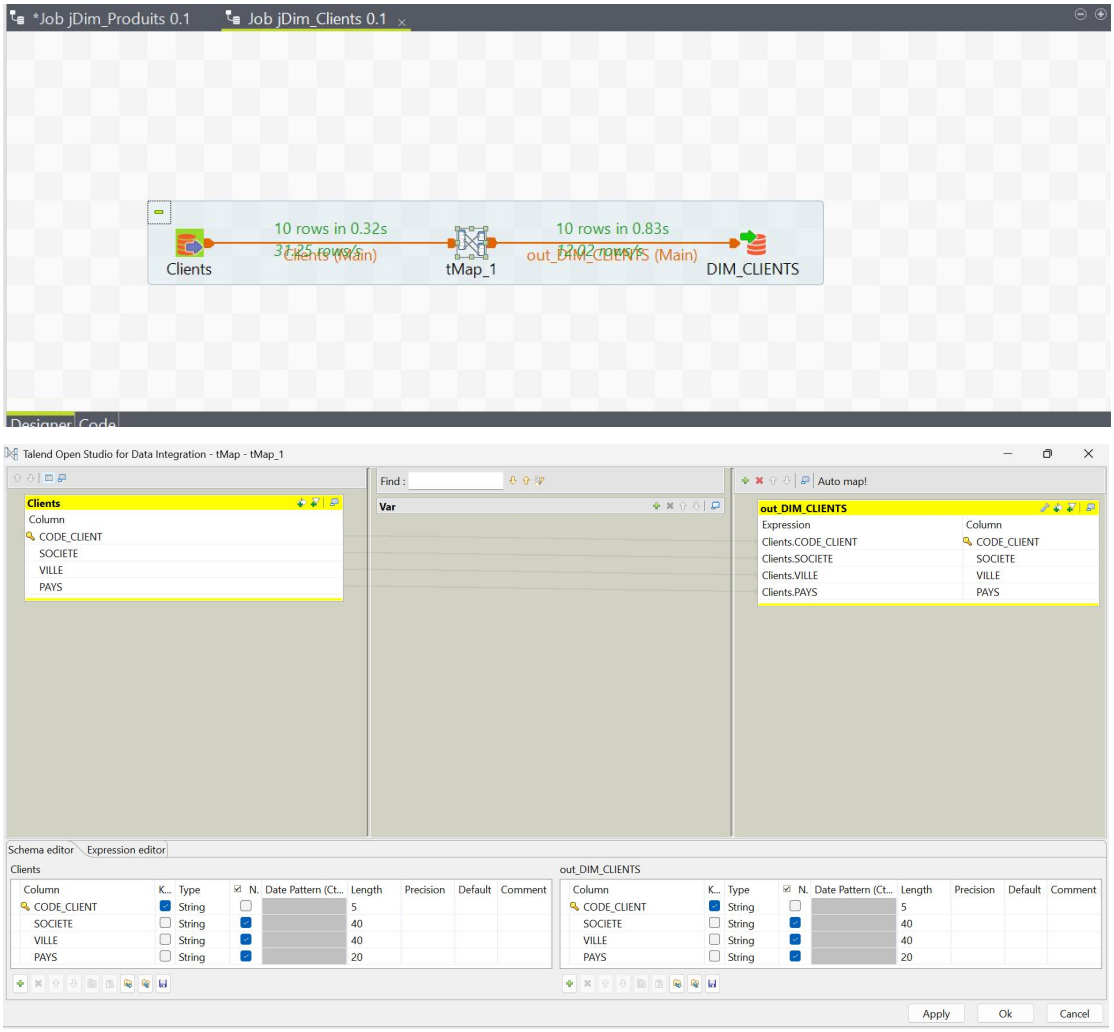

Les transformations effectuées permettent de nettoyer les données et de structurer les attributs nécessaires à la dimension client. Les données finales sont ensuite chargées dans la table **DIM_CLIENTS**, assurant ainsi une analyse des ventes selon les clients.

SQLQuery3.s...W (sa (65))*

```sql
USE comptoirDW
GO

Select * from DIM_CLIENTS;
```

100 % 1 0

Results Messages

	CODE_CLIENT	SOCIETE	VILLE	PAYS
1	CL001	Alpha Market	Casablanca	Maroc
2	CL002	TechZone	Rabat	Maroc
3	CL003	MaisonVerte	Marrakech	Maroc
4	CL004	ElectroMax	Fès	Maroc
5	CL005	SuperShop	Casablanca	Maroc
6	CL006	InfoPlus	Casablanca	Maroc
7	CL007	MobileCenter	Agadir	Maroc
8	CL008	HomeTech	Tanger	Maroc
9	CL009	DigitalStore	Oujda	Maroc
10	CL010	SmartWorld	Kenitra	Maroc

3.4 Dim_Temps

La dimension **Temps** (**Dim_Temps**) est créée afin de permettre l'analyse des données selon la dimension temporelle. Elle est construite à partir des dates des commandes et permet de générer plusieurs attributs comme le jour, le mois et l'année.

Cette étape est essentielle pour analyser l'évolution des ventes dans le temps. Les données transformées sont chargées dans la table **DIM_TEMPS**.

3.5 Table Fait

Cette étape correspond à la création de **la table de faits,** qui représente le cœur du modèle décisionnel. Les données sont extraites des tables de commandes et reliées aux différentes dimensions (Client, Produit, Temps).

Les mesures principales telles que la quantité, le montant et les délais sont calculées et chargées dans la table **FACT_COMMANDE**. Cette table permet l'analyse globale des ventes selon plusieurs axes.

Table de faits : contient les valeurs numériques analysées.

Cube : structure permettant l'analyse multidimensionnelle.

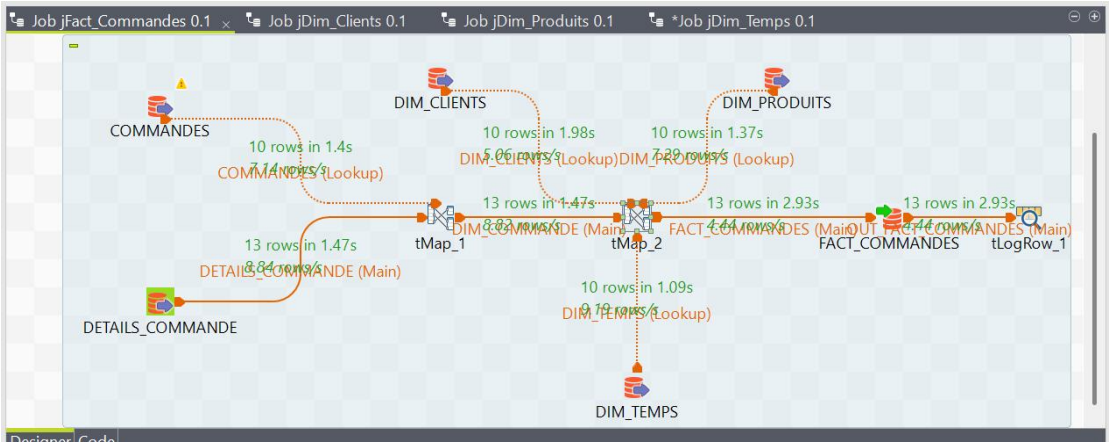

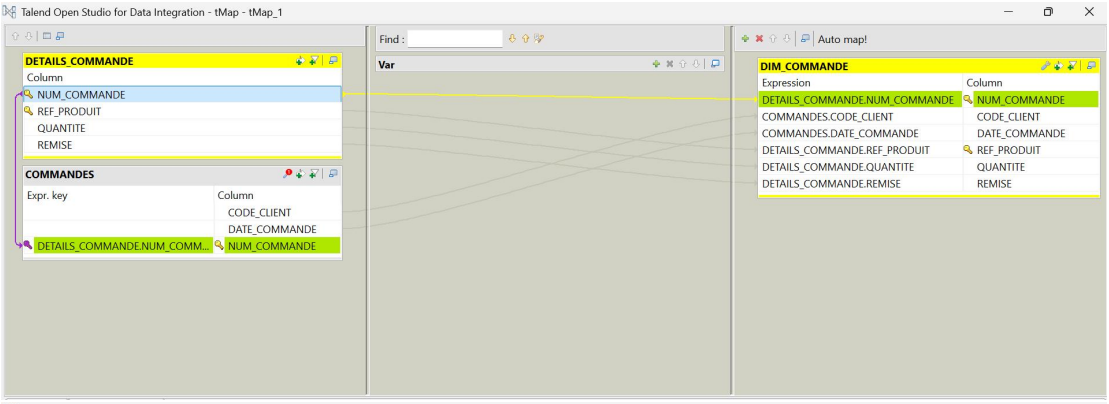

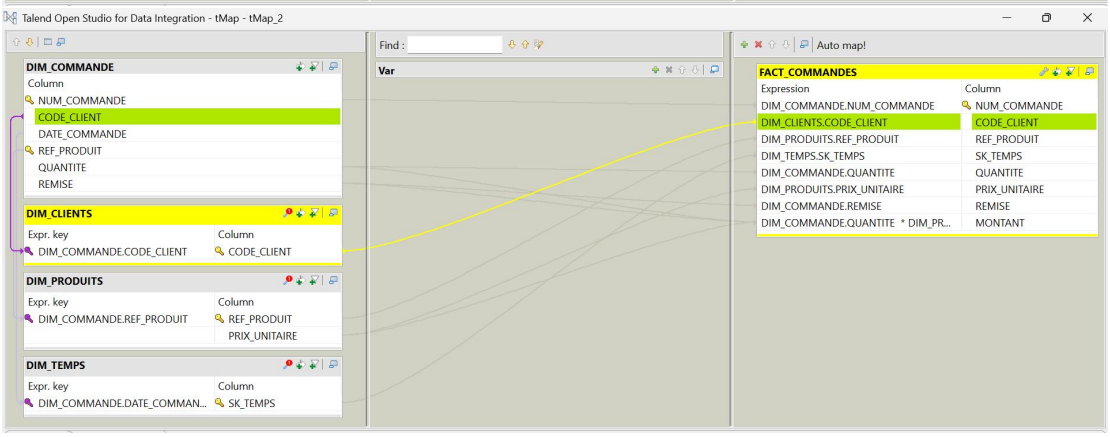

4. Conception de l'Entrepôt de Données

4.1 Schéma conceptuel de l'entrepôt

Un schéma conceptuel a été conçu afin de représenter les données et leurs relations de manière globale.

- Dans notre cas :

Dim_Clients : Cette table contient les informations relatives aux clients. Elle permet de segmenter et d'analyser les ventes selon les caractéristiques des clients. **Dim_Produits :** Cette table décrit les produits vendus ainsi que leur catégorie. Elle permet de réaliser des analyses par produit ou par catégorie.

Dim_Temps : Cette dimension temporelle permet d'effectuer des analyses par période : jour, mois, année, etc. Elle facilite la réalisation d'analyses temporelles précises et rapides.

Fait_Vente : La table de faits centralise les mesures chiffrées relatives aux ventes. Elle contient des clés étrangères pointant vers les dimensions et des indicateurs (mesures) permettant l'analyse.

4.2 Traduction en schéma R-OLAP

Le schéma conceptuel a été traduit en un schéma **R-OLAP**.

- **R-OLAP** : entrepôt de données basé sur une base relationnelle.

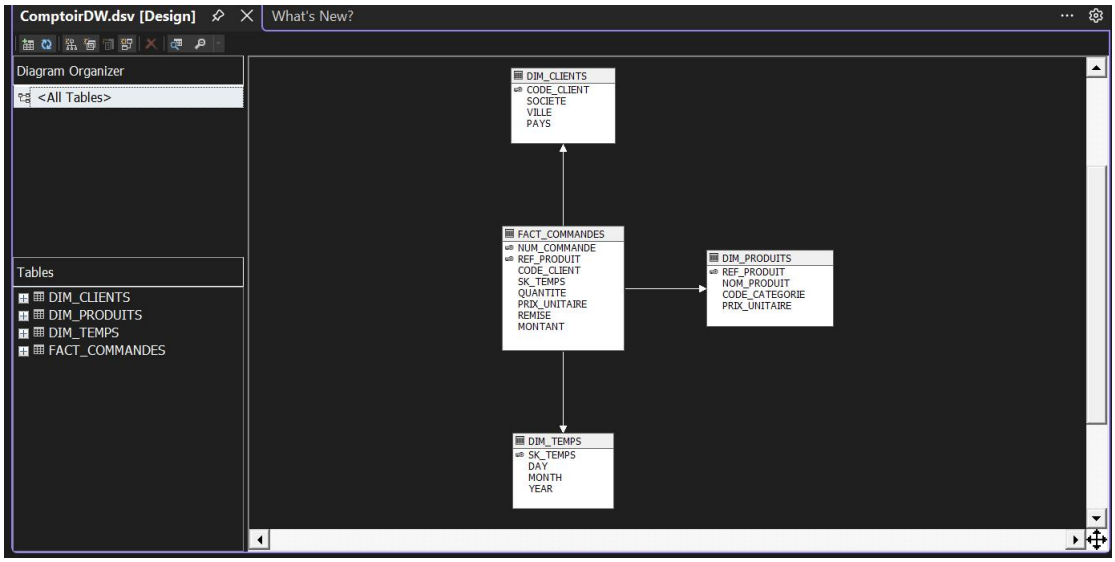

4.3 Modèle en étoile

Le modèle choisi est un **schéma en étoile**, composé d'une table centrale et de plusieurs tables de dimensions.

Schéma en étoile : modèle simple et performant pour l'analyse.

5. Analyse et Tableaux de Bord

Les principaux indicateurs analysés sont :

Chiffre d'affaires

Nombre de commandes

Ventes par produit et par client

Ensuite, nous avons créé plusieurs mesures (comme le chiffre d'affaires total, le nombre de ventes, etc.) et mis en avant des indicateurs clés dans les visuels de Power BI, afin de faciliter l'analyse et la prise de décision.

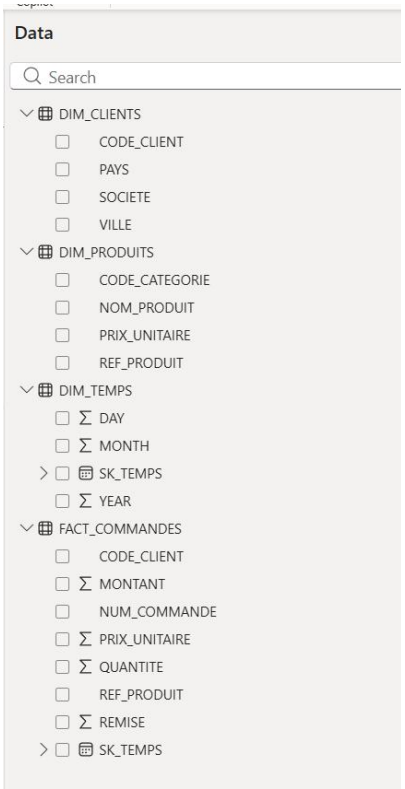

5.1 Répartition du Chiffre d'affaires par le nom de catégorie

Dimension utilisée : DIM_PRODUIT (champ CODE_CATEGORIE)
Mesure affichée : Sum(Montantl) depuis FAIT_VENTE
Cette visualisation compare le chiffre d'affaires généré par catégorie de produit. Elle utilise la dimension produit pour segmenter les ventes et identifier les catégories les plus rentables.

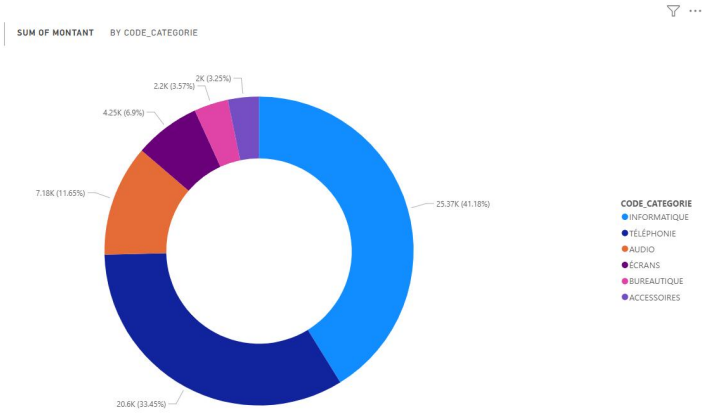

5.2 Quantité vendue par produit et par prix unitaire :

Dimension utilisée : DIM_PRODUIT (champ NOM_PRODUIT, PRIX_UNITAIRE)
Mesure affichée : Sum(QUANTITE)
Cette visualisation croise deux attributs de la dimension produit : le nom du produit et son prix unitaire. Elle donne une vue produit-prix-performance, utile pour savoir quels produits se vendent le plus selon leur prix.

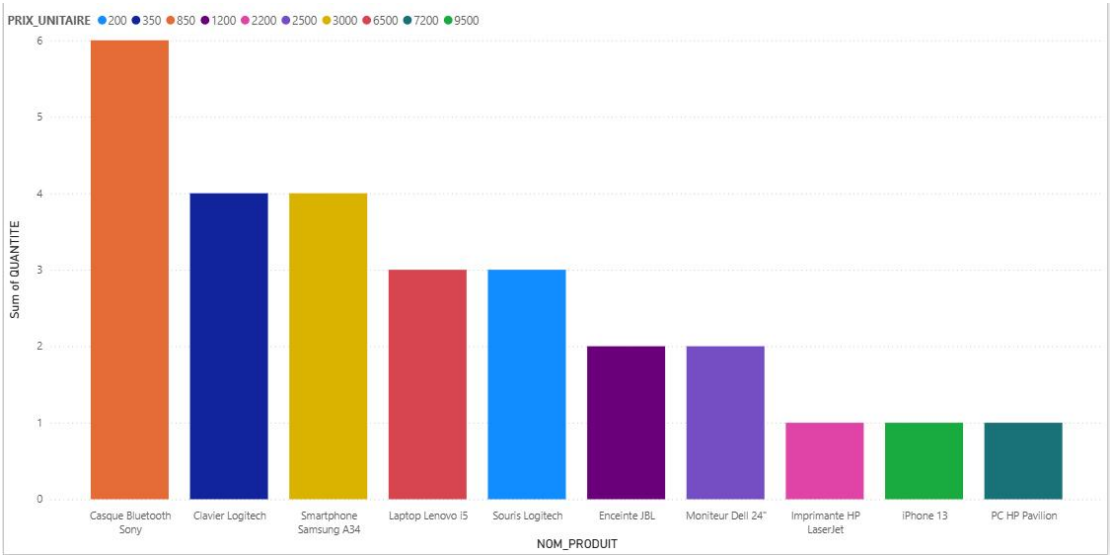

5.3 Somme des Prix unitaire par jour et par mois :

Dimension utilisée : DIM_TEMPS (niveau jour)

Mesure affichée : Sum(PRIX_UNITAIRE) depuis la table de faits Ce graphique permet d'analyser les ventes jour par jour et par mois. Il montre une analyse temporelle basée sur la dimension temps.

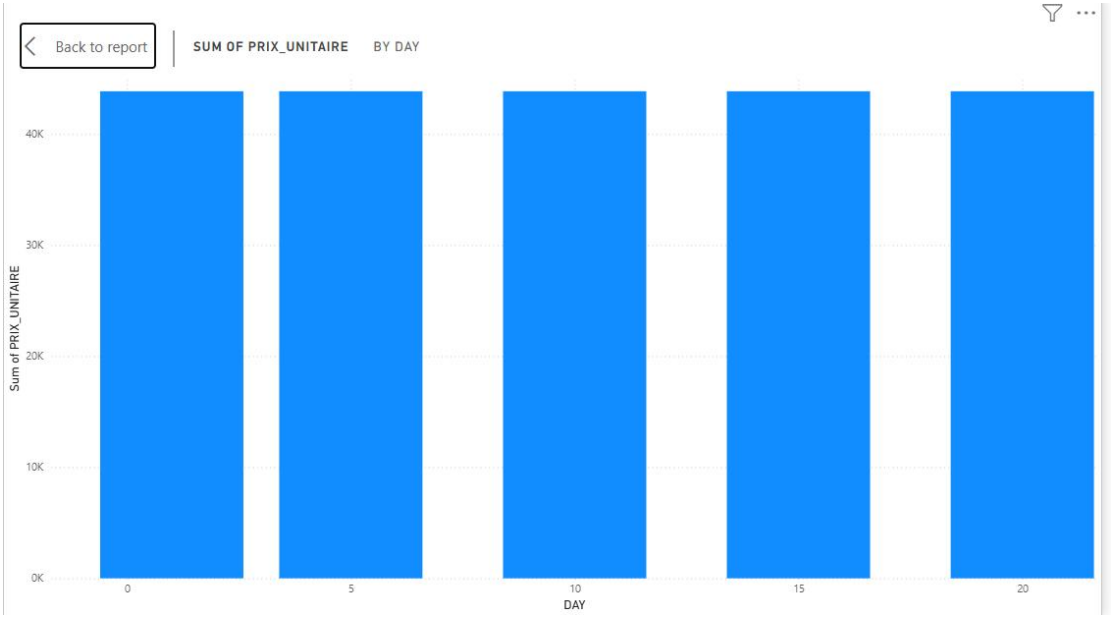

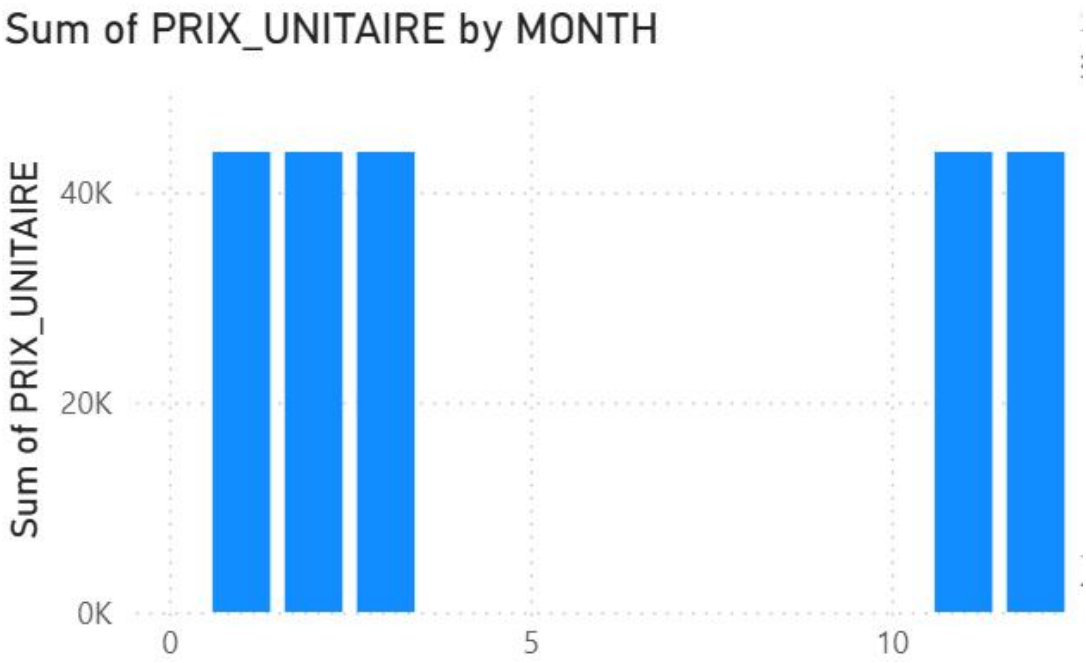

6. Data Mining

Clustering avec K-Means

L'algorithme **K-Means** a été utilisé pour regrouper les clients selon les retards de livraison.

- **Clustering** : regrouper des données similaires.
- **K-Means** : algorithme qui crée des groupes de clients ayant des comportements proches.

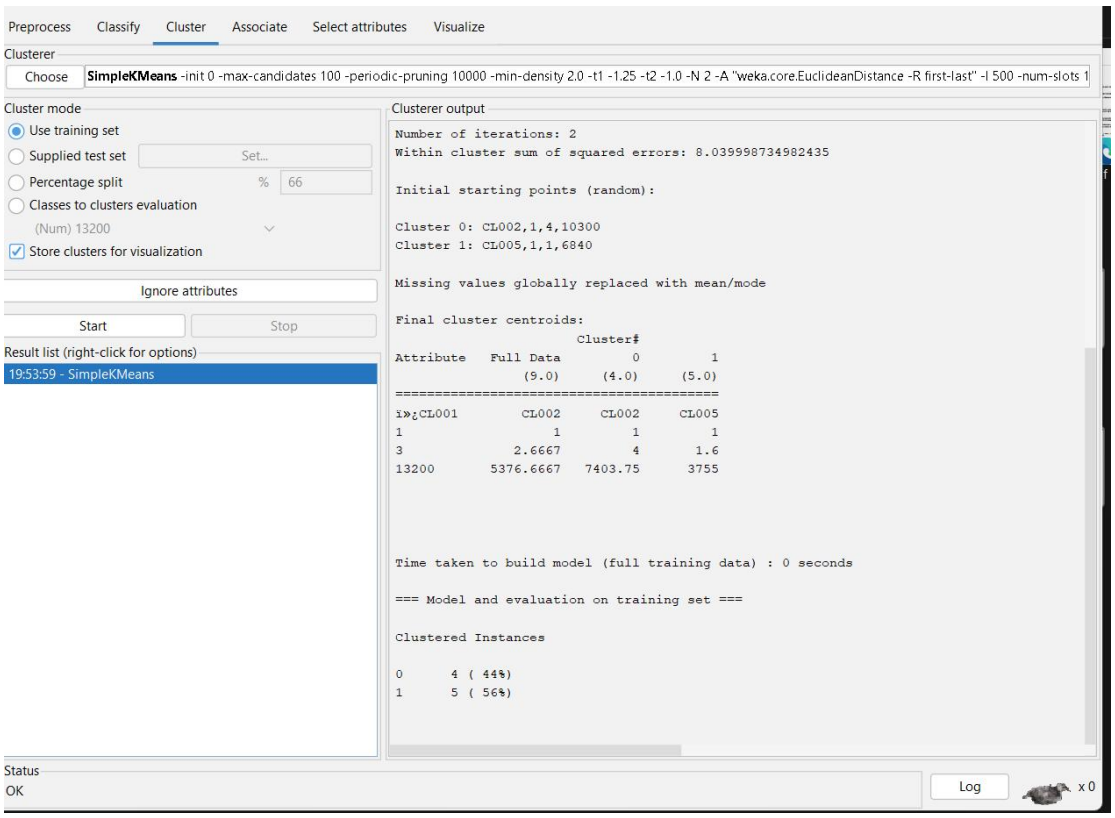

Conclusion

Ce projet a permis de mettre en pratique les concepts de la **Business Intelligence** et du **Data Mining**.

La conception de l'entrepôt de données, l'analyse via des tableaux de bord et l'application d'algorithmes de Data Mining ont montré l'importance de l'informatique décisionnelle dans la prise de décision.